Custo dos Servidores Contratados

Modelagem de Séries Temporais

Matheus de Moraes Neves Eduardo Henrique de Souza Dias

Sumário

Resumo **3**

1 Introdução **4**

2 Descrição da Base de Dados **5**
2.1 Dicionário de Variáveis Principais 5

3 Metodologia **7**
3.1 O Modelo SARIMA 7
3.2 Transformação Box-Cox 8
3.3 Critérios de Seleção do Modelo 8
3.4 Diagnóstico dos Resíduos 8
3.5 Avaliação Preditiva: Divisão Treino e Teste 9

4 Análise Exploratória da Série Temporal **10**
4.1 Decomposição da Série 11

5 Verificação de Estacionariedade e Transformações **14**
5.1 Estabilização da Variância (Box-Cox) 14
5.2 Teste de Raiz Unitária (KPSS) 14
5.3 Gráficos ACF e PACF 15

6 Identificação e Ajuste do Modelo **18**
6.1 Processo de Seleção 18
6.2 Modelo Selecionado 19

7 Diagnóstico dos Resíduos **21**

8 Comparação de Modelos e Validação Preditiva **23**
8.1 Divisão Treino e Teste 23
8.2 Comparação SARIMA, ETS e Prophet 24

9 Resultados **28**
9.1 Estimativas dos Parâmetros 28
9.2 Previsão para os Próximos 12 Meses 28

Referências **32**

Resumo

Este trabalho tem como objetivo modelar e prever a série temporal referente ao custo mensal com servidores contratados pela Prefeitura Municipal de Uberlândia (MG). A base de dados analisada compreende o período de janeiro de 2021 a outubro de 2025, totalizando 58 observações que foram previamente deflacionadas para refletir o custo real e mitigar o viés inflacionário. A etapa de análise exploratória e decomposição identificou uma quebra estrutural de patamar no início de 2022, seguida de estabilização, além de uma forte sazonalidade anual marcada por quedas drásticas nos meses de janeiro, reflexo direto da dinâmica administrativa de encerramento e renovação de contratos temporários. Para a etapa de previsão, adotou-se uma abordagem competitiva, testando e comparando modelos de Suavização Exponencial (ETS) e da classe SARIMA. O processo metodológico incluiu a transformação de Box-Cox para estabilização de variância e testes formais de raiz unitária para garantir a estacionariedade. A partir de critérios de informação (AICc) e métricas de erro preditivo (RMSE), um modelo SARIMA foi selecionado como o mais robusto. O diagnóstico dos resíduos atestou a validade do ajuste, confirmando a ausência de autocorrelação serial. Por fim, o modelo selecionado gerou previsões para um horizonte de 12 meses, projetando a manutenção da estabilidade financeira nos custos com pessoal temporário, preservando com precisão as flutuações sazonais inerentes à máquina pública municipal.

Palavras-chave: Séries Temporais, Previsão, SARIMA, Gastos Públicos, Sazonalidade.

1 Introdução

O presente trabalho tem como objetivo analisar e modelar a série temporal referente ao **custo mensal dos servidores contratados temporariamente** pela Prefeitura Municipal de Uberlândia, Minas Gerais. A gestão eficiente dos gastos com pessoal constitui um dos maiores desafios da administração pública brasileira, uma vez que esses custos representam parcela significativa do orçamento municipal e estão sujeitos a variações sazonais, mudanças estruturais e efeitos inflacionários que dificultam a análise e o planejamento de longo prazo.

Os dados utilizados foram extraídos do portal da transparência da Prefeitura de Uberlândia, abrangendo o período de janeiro de 2021 a outubro de 2025, com granularidade mensal, totalizando 58 observações. A variável de interesse é o custo bruto mensal com servidores contratados, deflacionada pelo Índice Nacional de Preços ao Consumidor Amplo (IPCA) com base em outubro de 2025, de modo a isolar o crescimento real da folha de pagamento dos efeitos puramente nominais da inflação.

Do ponto de vista metodológico, adotou-se a família de modelos **SARIMA** (*Seasonal Autoregressive Integrated Moving Average*), amplamente utilizada na literatura de previsão de séries temporais por sua capacidade de capturar simultaneamente estruturas de autocorrelação, tendência e sazonalidade. O processo de modelagem seguiu as etapas clássicas de Box-Jenkins: análise exploratória, verificação de estacionariedade, identificação dos parâmetros por meio dos gráficos de ACF e PACF, estimação, diagnóstico dos resíduos e previsão. Para efeito de comparação, também se ajustou um modelo de Alisamento Exponencial (ETS), avaliando o desempenho preditivo de ambas as abordagens em dados não vistos durante o treinamento.

Os resultados indicam que a série apresenta sazonalidade anual marcante, especialmente uma queda expressiva nos custos em janeiro, acompanhada de uma tendência de crescimento até meados de 2023 e posterior estabilização. O modelo $\text{SARIMA}(0,1,1)(0,1,1)_{12}$ foi selecionado com base nos critérios de informação AICc e BIC e seu diagnóstico confirmou resíduos sem autocorrelação serial, validando o ajuste para fins de previsão.

2 Descrição da Base de Dados

A base de dados utilizada neste estudo é composta por um conjunto de variáveis que detalham a estrutura de pessoal e a alocação de recursos financeiros da Prefeitura de Uberlândia. As variáveis estão organizadas em dois níveis principais: o nível geral, que consolida os dados de toda a administração municipal, e o nível específico, focado na Secretaria de Educação. Cada registro apresenta informações sobre o quantitativo de servidores em diferentes regimes jurídicos, como efetivos, comissionados e contratados temporários.

Além da contagem de pessoal, os dados discriminam os custos associados a cada categoria. Para a série principal deste estudo, focamos no custo bruto dos servidores contratados, que representa o montante mensal destinado ao pagamento de salários desses profissionais. A base também oferece variáveis complementares que detalham verbas específicas, como horas extras, anuênios e adicionais de insalubridade, além de informações sobre o fluxo de pessoal, incluindo registros de admissões, desligamentos e aposentadorias ocorridos em cada mês.

2.1 Dicionário de Variáveis Principais

Variável	Definição
`data_ref`	Data de referência do registro mensal.
`Geral.Custo.dos.Servidores.Contratados`	Variável dependente (Y) representando o custo em reais.
`Geral.Admissões.Total`	Total de novos servidores admitidos no mês.
`Geral.Registros.Gerais.Total`	Total de desligamentos e movimentações de pessoal.

Devido à extensão da série histórica, os valores registrados em reais correntes estão sujeitos aos efeitos da perda do poder de compra da moeda ao longo do período analisado. Para contornar esse viés econômico e refletir o aumento efetivo dos gastos municipais, aplicamos uma correção inflacionária na variável de custo. Esse processo de deflacionamento foi realizado por meio do ajuste de todos os valores históricos para a data-base de referência de outubro de 2025, utilizando o IPCA. Conforme observado na Figura 1, a série real apresenta valores sistematicamente superiores aos nominais nos anos iniciais, evidenciando que o crescimento dos gastos foi, em termos de poder de compra, ainda mais acentuado do que os números brutos sugeriam.

```
dados = dados %>%
  mutate(
    Custo_Real = deflate(
      nominal_values = Geral.Custo.dos.Servidores.Contratados,
```

```
      nominal_dates  = data_ref,
      real_date      = "10/2025",
      index          = "ipca"
    )
  )

ggplot(dados) +
  geom_line(aes(x = data_ref,
                y = Geral.Custo.dos.Servidores.Contratados,
                color = "Nominal"),
            linetype = "dashed", linewidth = 0.7) +
  geom_line(aes(x = data_ref, y = Custo_Real, color = "Real"), linewidth = 1) +
  scale_color_manual(values = c("Nominal" = "gray60", "Real" = "steelblue")) +
  scale_y_continuous(labels = scales::label_number(prefix = "R$ ",
                                                   big.mark = ".",
                                                   decimal.mark = ",")) +
  theme_minimal() +
  labs(x = "Ano", y = "Valor", color = "Série")
```

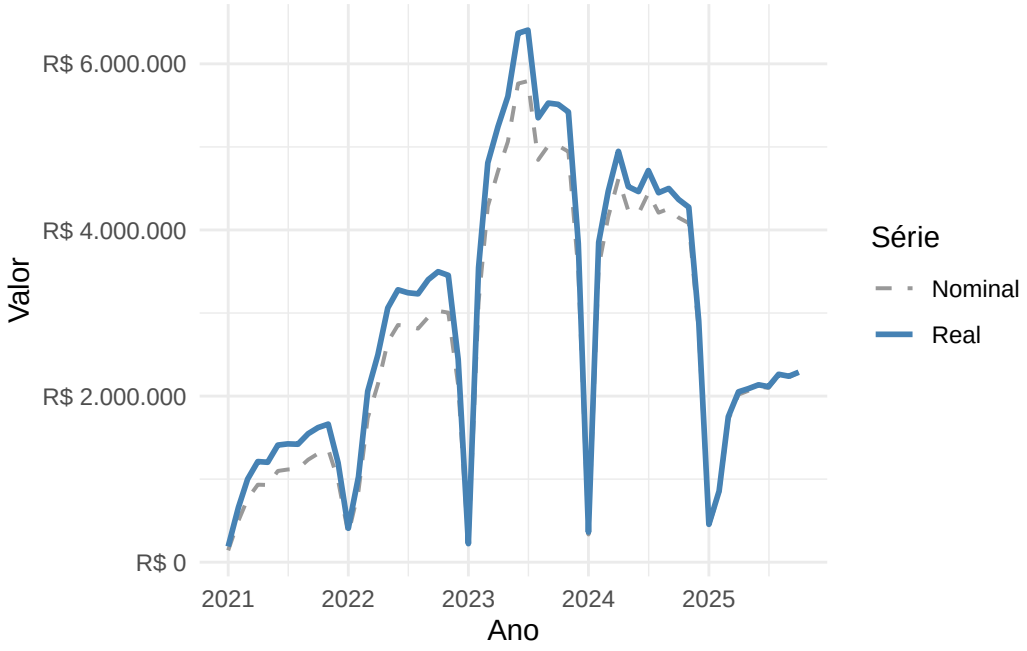

Figura 1: Comparação entre o custo nominal e o custo real deflacionado pelo IPCA (base outubro/2025).

3 Metodologia

3.1 O Modelo SARIMA

O modelo SARIMA (*Seasonal Autoregressive Integrated Moving Average*) é uma extensão do modelo ARIMA clássico que incorpora componentes sazonais à estrutura de autocorrelação. Sua notação completa é SARIMA$(p, d, q)(P, D, Q)_s$, onde s denota o período sazonal (neste trabalho, $s = 12$ meses).

O modelo é definido pelo operador de atraso B, tal que $B^k Y_t = Y_{t-k}$, e pelas seguintes componentes:

Parte não-sazonal:

- $\phi_p(B) = 1 - \phi_1 B - \phi_2 B^2 - \cdots - \phi_p B^p$ — polinômio AR de ordem p
- $\theta_q(B) = 1 + \theta_1 B + \theta_2 B^2 + \cdots + \theta_q B^q$ — polinômio MA de ordem q
- $(1 - B)^d$ — operador de diferenciação de ordem d

Parte sazonal:

- $\Phi_P(B^s) = 1 - \Phi_1 B^s - \cdots - \Phi_P B^{Ps}$ — polinômio SAR de ordem P
- $\Theta_Q(B^s) = 1 + \Theta_1 B^s + \cdots + \Theta_Q B^{Qs}$ — polinômio SMA de ordem Q
- $(1 - B^s)^D$ — operador de diferenciação sazonal de ordem D

A equação geral do modelo é:

$$\Phi_P(B^s)\,\phi_p(B)\,(1-B)^d\,(1-B^s)^D\,Y_t = \Theta_Q(B^s)\,\theta_q(B)\,\varepsilon_t$$

onde $\varepsilon_t \sim \mathrm{RB}(0, \sigma^2)$ é um processo de ruído branco com média zero e variância constante. Para o modelo selecionado neste trabalho, SARIMA$(0,1,1)(0,1,1)_{12}$, não há componentes autorregressivos ($p = P = 0$), de modo que a equação se simplifica a:

$$(1-B)(1-B^{12})\,Y_t^{(\lambda)} = (1+\theta_1 B)(1+\Theta_1 B^{12})\,\varepsilon_t$$

onde $Y_t^{(\lambda)}$ denota a série após a transformação Box-Cox com $\lambda = 0{,}2997$.

3.2 Transformação Box-Cox

Quando a série apresenta heterocedasticidade, isto é, variância que cresce ou decresce ao longo do tempo, aplica-se a transformação de Box-Cox antes da modelagem:

$$Y_t^{(\lambda)} = \begin{cases} \dfrac{Y_t^{\lambda} - 1}{\lambda}, & \lambda \neq 0 \\ \ln(Y_t), & \lambda = 0 \end{cases}$$

O valor ótimo de λ é estimado maximizando a função de verossimilhança perfilada da série. Valores próximos de 0 indicam necessidade de transformação logarítmica; valores próximos de 1 indicam que a série não requer transformação.

3.3 Critérios de Seleção do Modelo

A seleção entre modelos alternativos foi realizada com base nos critérios de informação AICc (*Corrected Akaike Information Criterion*) e BIC (*Bayesian Information Criterion*):

$$\text{AICc} = -2\ln(\hat{L}) + 2k + \frac{2k(k+1)}{n-k-1}, \qquad \text{BIC} = -2\ln(\hat{L}) + k\ln(n)$$

onde $\hat{L}$ é a verossimilhança maximizada, k é o número de parâmetros e n o tamanho da amostra. Modelos com menores valores de AICc e BIC são preferidos.

3.4 Diagnóstico dos Resíduos

A adequação do modelo é avaliada por três critérios complementares:

1. **Teste de Ljung-Box**: testa se os resíduos são serialmente não correlacionados (hipótese nula de ausência de autocorrelação). A estatística é $Q^* = n(n+2)\sum_{k=1}^{h} \frac{\hat{\rho}_k^2}{n-k}$.
2. **Teste de Shapiro-Wilk**: avalia se os resíduos seguem uma distribuição normal.
3. **Análise gráfica**: inspeção visual dos gráficos de resíduos ao longo do tempo, ACF dos resíduos e histograma.

3.5 Avaliação Preditiva: Divisão Treino e Teste

Para avaliar o desempenho dos modelos em dados não observados durante o ajuste, a série foi dividida em dois subconjuntos. Os primeiros $n-h$ meses foram utilizados para treinamento e os últimos $h = 12$ meses foram reservados como conjunto de teste. Essa abordagem, conhecida como *hold-out evaluation*, é recomendada por Hyndman & Athanasopoulos (2021) como forma de simular o cenário real de previsão e evitar que métricas de ajuste em amostra superestimem a capacidade preditiva do modelo. A escolha de 12 meses como horizonte de teste é especialmente adequada neste contexto, pois permite verificar se o modelo captura corretamente um ciclo sazonal completo fora da amostra.

Os modelos foram retreinados exclusivamente nos dados de treino e suas previsões para o período de teste foram comparadas aos valores reais por meio do RMSE (*Root Mean Squared Error*) e do MAPE (*Mean Absolute Percentage Error*):

$$\text{RMSE} = \sqrt{\frac{1}{h}\sum_{t=1}^{h}(y_t - \hat{y}_t)^2}, \qquad \text{MAPE} = \frac{100}{h}\sum_{t=1}^{h}\left|\frac{y_t - \hat{y}_t}{y_t}\right|$$

4 Análise Exploratória da Série Temporal

A série analisada corresponde ao registro mensal do custo dos servidores contratados no âmbito geral da Prefeitura Municipal de Uberlândia. Os dados cobrem o período de janeiro de 2021 a outubro de 2025, totalizando 58 observações, sem valores faltantes. Essa característica favorece a aplicação direta de modelos de séries temporais estruturados, como o SARIMA, sem a necessidade de técnicas prévias de imputação. Os valores observados variam de aproximadamente R$,142.396, 57 em janeiro de 2021 a topico de R,$5.792.573,85 em julho de 2023, evidenciando uma amplitude considerável na folha de pagamento ao longo do período.

A Figura 2 apresenta o comportamento da série ao longo do tempo.

```
serie = ts(dados$Custo_Real,
           start     = c(2021, 1),
           frequency = 12)

ggplot(dados, aes(x = data_ref, y = Custo_Real)) +
  geom_line(color = "steelblue", linewidth = 0.8) +
  geom_point(aes(color = format(data_ref, "%m") == "01"), size = 2) +
  scale_color_manual(values = c("black", "red"), guide = "none") +
  scale_y_continuous(labels = scales::label_number(prefix = "R$ ",
                                                   big.mark = ".",
                                                   decimal.mark = ",")) +
  scale_x_date(date_breaks = "6 months", date_labels = "%b %Y") +
  theme_minimal() +
  labs(x = "Tempo", y = "Custo (R$)") +
  theme(axis.text.x = element_text(angle = 45, hjust = 1))
```

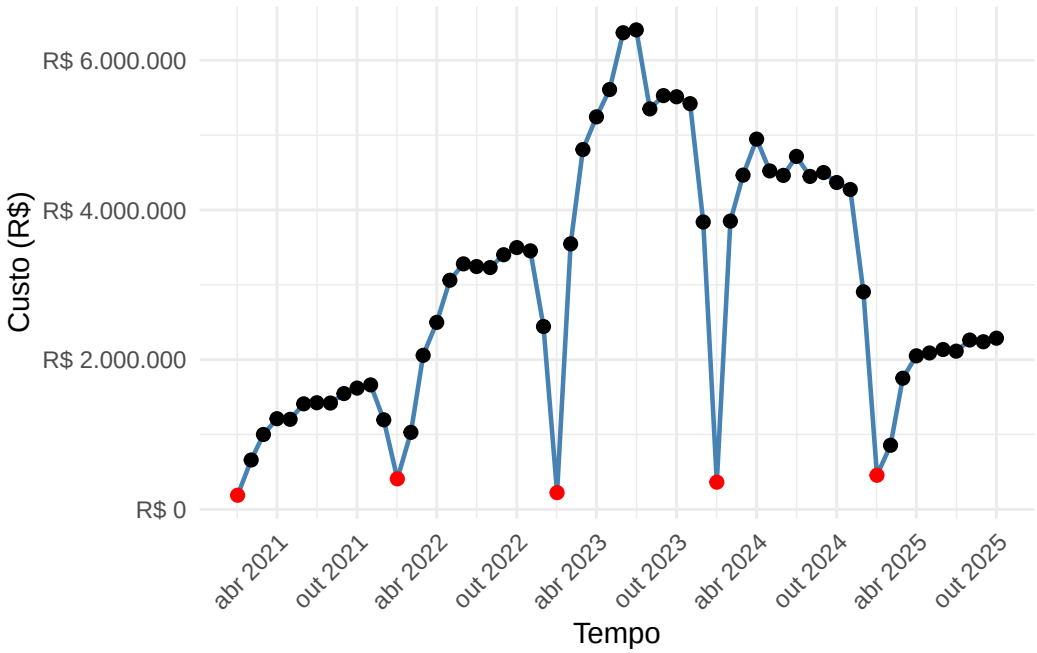

Figura 2: Evolução do custo mensal real com servidores contratados (2021–2025). Pontos vermelhos indicam janeiro.

A série exibe visualmente três características relevantes: uma tendência de crescimento expressivo entre 2021 e 2023, uma sazonalidade anual marcada pela queda abrupta em janeiro de cada ano, e uma volatilidade que cresce junto com o nível da série, sugerindo heterocedasticidade. Essas observações preliminares orientam as etapas de transformação e modelagem descritas nas seções seguintes.

4.1 Decomposição da Série

Para avaliar formalmente as componentes estruturais da série, aplicou-se a decomposição STL (*Seasonal and Trend decomposition using Loess*), que isola tendência, sazonalidade e resíduo de forma robusta, conforme a Figura 3.

```
decomposicao = stl(serie, s.window = "periodic")

autoplot(decomposicao) +
  theme_minimal() +
  labs(x = "Ano")
```

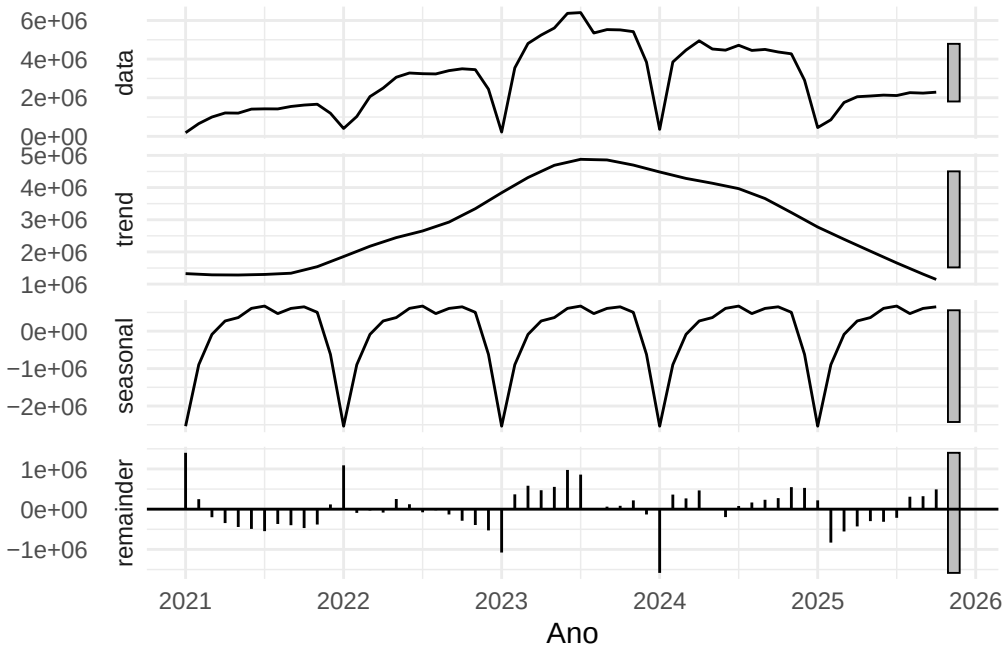

Figura 3: Decomposição STL da série: tendência (trend), sazonalidade (seasonal) e ruído (remainder).

O componente de **tendência** revela um provável ponto de mudança estrutural no início de 2022, quando os valores mensais passaram a operar em patamar significativamente superior ao do ano anterior, possivelmente reflexo de uma expansão no quadro de contratados. A tendência de alta prosseguiu até meados de 2023, seguida por sinais de estabilização a partir de 2024. O componente **sazonal** captura o comportamento recorrente de queda abrupta em janeiro, condizente com a dinâmica de encerramento e renovação de contratos temporários no setor público. O componente **residual**, por sua vez, não se comporta como ruído branco puro, apresentando picos estruturais associados às quebras de patamar da série original. Essa ausência de aleatoriedade total sugere presença de heterocedasticidade ou efeitos multiplicativos que a decomposição clássica não captura plenamente, justificando a modelagem estocástica complementar.

```
ggplot(dados, aes(format(data_ref, "%m"), Custo_Real)) +
  geom_boxplot(fill = "steelblue", alpha = 0.4) +
  scale_y_continuous(labels = scales::label_number(prefix = "R$ ",
                                                   big.mark = ".",
                                                   decimal.mark = ",")) +
  theme_minimal() +
  labs(x = "Mês (01 = Janeiro)", y = "Distribuição de Custos")
```

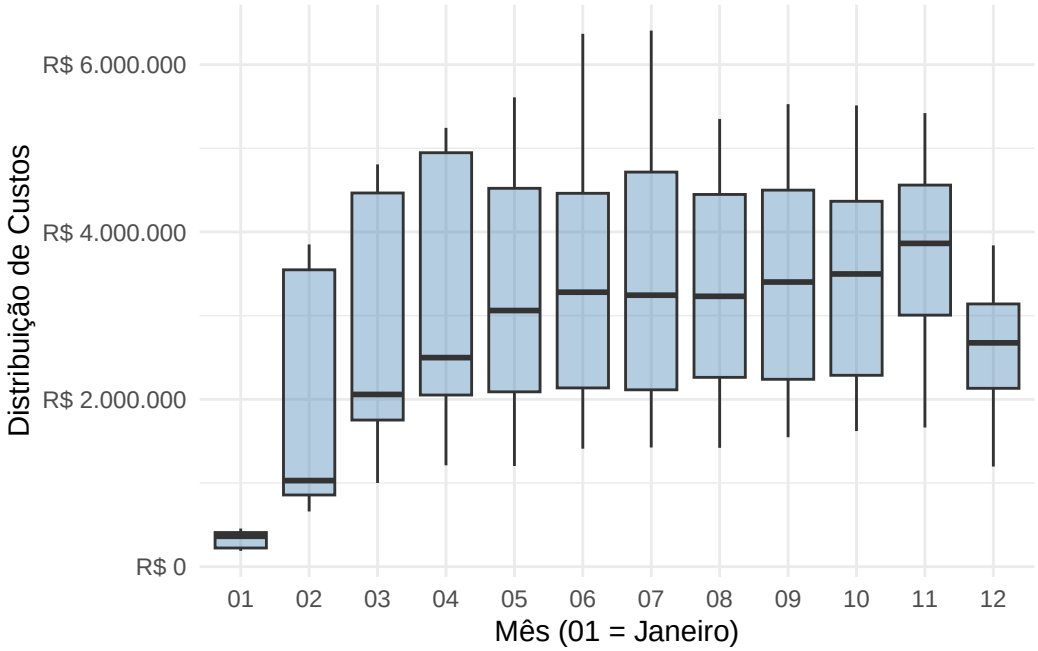

Figura 4: Distribuição mensal do custo real, evidenciando o forte padrão sazonal de queda em janeiro.

A Figura 4 reforça esse padrão: o mês de janeiro concentra sistematicamente os menores valores da série, enquanto os meses de março a novembro apresentam custos substancialmente mais elevados. Esse comportamento impõe a necessidade de modelos capazes de capturar sazonalidade com período $s = 12$.

5 Verificação de Estacionariedade e Transformações

5.1 Estabilização da Variância (Box-Cox)

Antes de diferenciar a série, verificamos a necessidade de estabilizar a variância por meio da transformação de Box-Cox. O valor ótimo de λ foi estimado pela função `BoxCox.lambda()`:

```
lambda_valor = BoxCox.lambda(serie)
cat("Valor de Lambda estimado:", round(lambda_valor, 4))
```

```
Valor de Lambda estimado: 0.2997
```

O valor estimado de $\lambda = 0{,}2997$ está próximo de zero, indicando que a série se beneficia de uma transformação próxima à logarítmica para estabilizar a variância ao longo do tempo. Essa transformação é incorporada diretamente no ajuste do modelo SARIMA por meio do argumento `lambda`, e todas as estimativas e previsões são automaticamente revertidas para a escala original ao final.

5.2 Teste de Raiz Unitária (KPSS)

Aplicou-se o teste KPSS para verificar formalmente a estacionariedade da série transformada. Diferentemente do teste ADF, no KPSS a hipótese nula é de que a série **é estacionária**, de modo que valores elevados da estatística de teste levam à rejeição dessa hipótese.

```
serie_transf = BoxCox(serie, lambda = lambda_valor)

kpss_result = ur.kpss(serie_transf)
summary(kpss_result)
```

```
#######################
# KPSS Unit Root Test #
#######################

Test is of type: mu with 3 lags.

Value of test-statistic is: 0.5003

Critical value for a significance level of:
                10pct  5pct 2.5pct  1pct
critical values 0.347 0.463  0.574 0.739
```

```r
ndiffs_val  = ndiffs(serie_transf)
nsdiffs_val = nsdiffs(serie_transf)
cat("Diferenciações simples (d) sugeridas:  ", ndiffs_val,  "\n")
```

```
Diferenciações simples (d) sugeridas:   1
```

```r
cat("Diferenciações sazonais (D) sugeridas:", nsdiffs_val, "\n")
```

```
Diferenciações sazonais (D) sugeridas: 1
```

A estatística de teste obtida foi 0,5003, que supera o valor crítico de 0,463 ao nível de significância de 5%, levando à rejeição da hipótese nula de estacionariedade. As funções `ndiffs()` e `nsdiffs()` indicaram, respectivamente, uma diferenciação simples ($d = 1$) e uma diferenciação sazonal ($D = 1$), parâmetros que serão incorporados diretamente no modelo SARIMA.

5.3 Gráficos ACF e PACF

Os gráficos de Autocorrelação (ACF) e Autocorrelação Parcial (PACF) orientam a identificação inicial dos parâmetros (p, q, P, Q), tanto antes quanto depois da diferenciação.

```r
ggtsdisplay(serie_transf,
            main    = "Série Transformada - Sem Diferenciação",
            lag.max = 36)
```

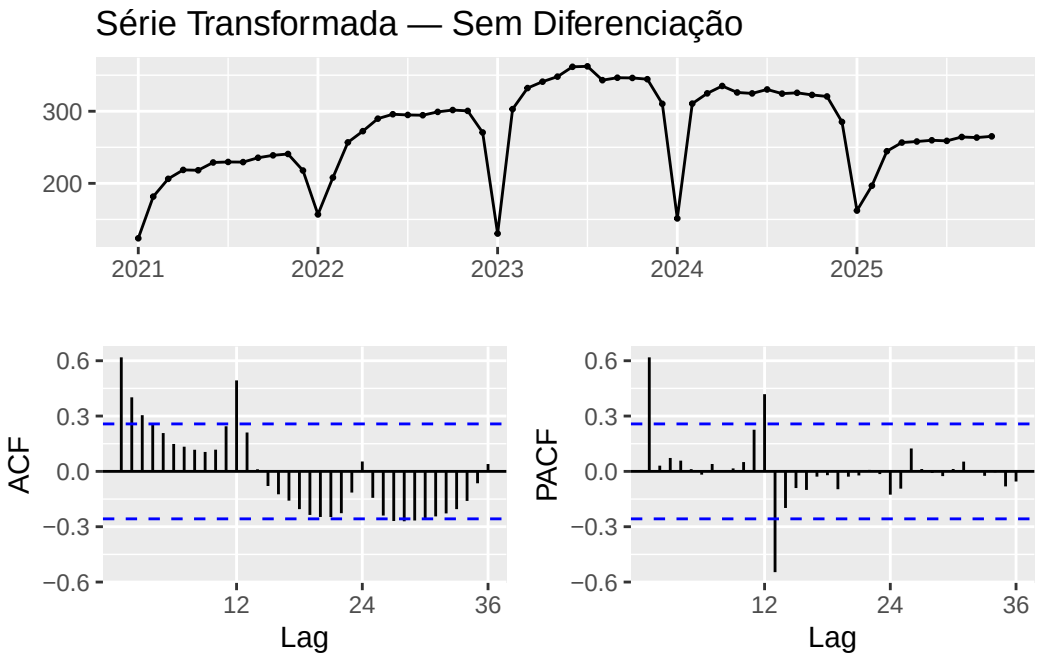

Figura 5: ACF e PACF da série transformada sem diferenciação, evidenciando não-estacionariedade pelo decaimento lento das autocorrelações.

Na Figura 5, o ACF exibe decaimento lento e persistente, confirmando a não-estacionariedade identificada pelo teste KPSS. Após aplicar a diferenciação simples e sazonal, obtém-se a série estacionária apresentada na Figura 6.

```
serie_estac = diff(diff(serie_transf, lag = 12), differences = 1)

ggtsdisplay(serie_estac,
            main    = "Série Diferenciada - Estacionária",
            lag.max = 36)
```

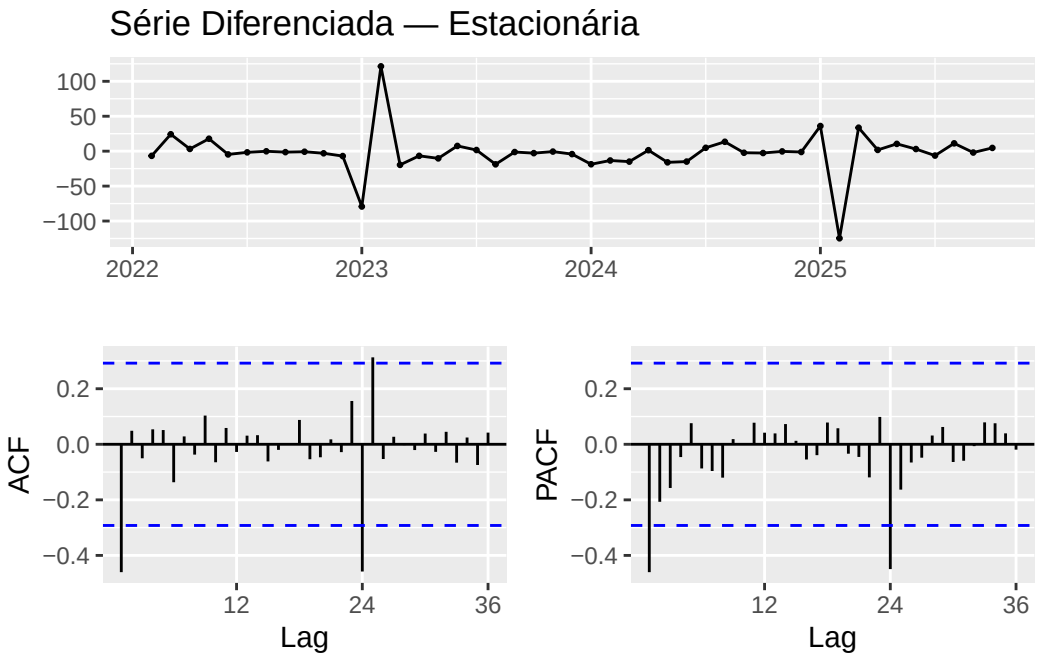

Figura 6: ACF e PACF após diferenciação sazonal (lag 12) e simples, com a série próxima de estacionária.

Na série diferenciada, o ACF apresenta um corte significativo após o lag 1 na parte não-sazonal e após o lag 12 na parte sazonal, enquanto o PACF exibe decaimento nos lags sazonais. Esse padrão é característico de um processo de médias móveis simples e sazonal, orientando a tentativa inicial de modelos com $q = 1$ e $Q = 1$.

6 Identificação e Ajuste do Modelo

6.1 Processo de Seleção

Com a série estabilizada e diferenciada, estimaram-se múltiplos modelos SARIMA para identificar a estrutura mais adequada. O algoritmo `auto.arima()` foi utilizado com busca exaustiva (`stepwise = FALSE`, `approximation = FALSE`) para garantir que o espaço de modelos fosse explorado de forma abrangente, sem atalhos que pudessem levar a soluções subótimas:

```
modelo_auto = auto.arima(serie,
                         lambda        = lambda_valor,
                         stepwise      = FALSE,
                         approximation = FALSE)
summary(modelo_auto)
```

```
Series: serie
ARIMA(0,1,1)(0,1,1)[12]
Box Cox transformation: lambda= 0.2996605

Coefficients:
          ma1    sma1
      -0.5885  0.6412
s.e.   0.1142  0.3495

sigma^2 = 618.4:  log likelihood = -210.73
AIC=427.46   AICc=428.05   BIC=432.88

Training set error measures:
                    ME     RMSE      MAE       MPE     MAPE      MASE      ACF1
Training set -134238.9 760780.4 396583.7 -8.147968 18.59008 0.2363422 0.3672363
```

O algoritmo selecionou o modelo SARIMA$(0,1,1)(0,1,1)_{12}$ com AICc de 428,05 e BIC de 432,88. Para verificar se essa escolha era de fato a mais adequada, estimaram-se também modelos alternativos com variações nos parâmetros (p, q, P, Q) guiadas pelos gráficos de ACF e PACF. A Tabela 2 apresenta a comparação pelos critérios de informação.

```
m1 = Arima(serie, order = c(0,1,1), seasonal = c(1,0,0), lambda = lambda_valor)
m2 = Arima(serie, order = c(1,1,1), seasonal = c(1,0,0), lambda = lambda_valor)
m3 = Arima(serie, order = c(0,1,1), seasonal = c(0,1,1), lambda = lambda_valor)
m4 = Arima(serie, order = c(1,1,0), seasonal = c(1,0,0), lambda = lambda_valor)
```

```r
m5 = Arima(serie, order = c(0,1,2), seasonal = c(1,0,0), lambda = lambda_valor)

tab_modelos = data.frame(
  Modelo = c("SARIMA(0,1,1)(1,0,0)[12]",
             "SARIMA(1,1,1)(1,0,0)[12]",
             "SARIMA(0,1,1)(0,1,1)[12]  *",
             "SARIMA(1,1,0)(1,0,0)[12]",
             "SARIMA(0,1,2)(1,0,0)[12]"),
  AICc   = c(m1$aicc, m2$aicc, m3$aicc, m4$aicc, m5$aicc),
  BIC    = c(m1$bic,  m2$bic,  m3$bic,  m4$bic,  m5$bic)
)

tab_modelos = tab_modelos %>%
  mutate(across(c(AICc, BIC), \(x) round(x, 2)))

kable(tab_modelos, align = "lcc")
```

Tabela 2: Comparação de modelos SARIMA candidatos pelos critérios AICc e BIC. Asterisco indica o modelo selecionado.

Modelo	AICc	BIC
SARIMA(0,1,1)(1,0,0)[12]	549.06	554.73
SARIMA(1,1,1)(1,0,0)[12]	551.25	558.66
SARIMA(0,1,1)(0,1,1)[12] *	428.05	432.88
SARIMA(1,1,0)(1,0,0)[12]	551.75	557.42
SARIMA(0,1,2)(1,0,0)[12]	551.27	558.67

Os resultados são bastante conclusivos. Os modelos que incluíam diferenciação sazonal ($D = 1$) apresentaram desempenho claramente superior aos que utilizavam um componente autorregressivo sazonal ($P = 1,\ D = 0$). Os quatro modelos com estrutura ($P = 1, D = 0$) obtiveram valores de AICc acima de 549, ao passo que o SARIMA$(0,1,1)(0,1,1)_{12}$ registrou AICc de 428,05, uma diferença superior a 120 pontos. Diferenças de AICc acima de 10 já são consideradas evidência forte em favor de um modelo, portanto esse resultado indica que a diferenciação sazonal é indispensável para capturar a estrutura desta série. Esse achado é coerente com o que o gráfico ACF havia antecipado: correlações sazonais fortes e persistentes requerem diferenciação, não apenas um componente AR sazonal.

6.2 Modelo Selecionado

O modelo escolhido, SARIMA$(0,1,1)(0,1,1)_{12}$, possui dois parâmetros estimados: o coeficiente de médias móveis não-sazonal (θ_1) e o coeficiente de médias móveis sazonal (Θ_1). Sua equação

explícita, após as diferenciações, é:

$$(1-B)(1-B^{12})\,Y_t^{(\lambda)} = (1+\theta_1 B)(1+\Theta_1 B^{12})\,\varepsilon_t$$

```r
modelos_lista = list(m1, m2, m3, m4, m5)
aicc_vals     = sapply(modelos_lista, function(m) m$aicc)
modelo_final  = modelos_lista[[which.min(aicc_vals)]]

summary(modelo_final)
```

```
Series: serie
ARIMA(0,1,1)(0,1,1)[12]
Box Cox transformation: lambda= 0.2996605

Coefficients:
          ma1    sma1
      -0.5885  0.6412
s.e.   0.1142  0.3495

sigma^2 = 618.4:  log likelihood = -210.73
AIC=427.46   AICc=428.05   BIC=432.88

Training set error measures:
                    ME     RMSE      MAE       MPE     MAPE      MASE      ACF1
Training set -134238.9 760780.4 396583.7 -8.147968 18.59008 0.2363422 0.3672363
```

Os coeficientes estimados foram $\hat{\theta}_1 = -0{,}5885$ (erro padrão 0,1142) e $\hat{\Theta}_1 = 0{,}6412$ (erro padrão 0,3495). O sinal negativo de $\hat{\theta}_1$ indica que choques positivos no período imediatamente anterior tendem a ser revertidos no período corrente. O sinal positivo de $\hat{\Theta}_1$ captura a persistência do padrão sazonal ao longo dos ciclos anuais: um mês com custo acima do esperado tende a ser seguido, doze meses depois, por outro mês também acima do esperado.

7 Diagnóstico dos Resíduos

A validação do modelo exige que os resíduos se comportem como ruído branco: sem autocorrelação serial, com média próxima de zero e distribuição idealmente normal. A Figura 7 apresenta os gráficos de diagnóstico.

```
checkresiduals(modelo_final)
```

```
    Ljung-Box test

data:  Residuals from ARIMA(0,1,1)(0,1,1)[12]
Q* = 6.2283, df = 10, p-value = 0.7957

Model df: 2.   Total lags used: 12
```

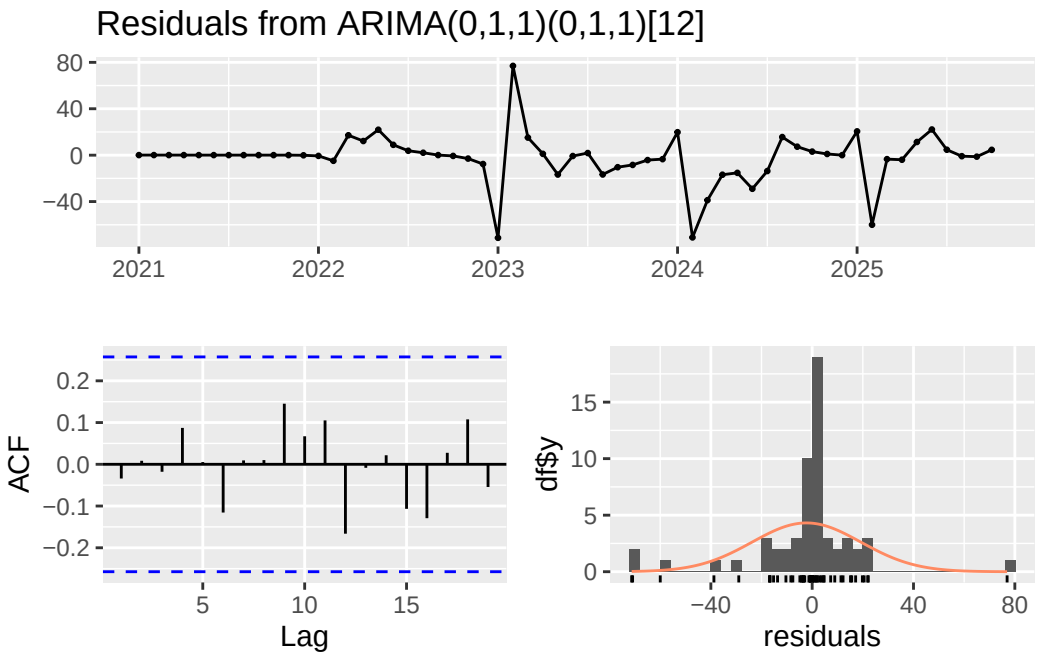

Figura 7: Diagnóstico dos resíduos do SARIMA(0,1,1)(0,1,1)[12]: série temporal dos resíduos, ACF e histograma.

Teste de Ljung-Box: o teste resultou em $Q^* = 6{,}2283$ com 10 graus de liberdade e p-valor de 0,7957.

```r
lb_test = Box.test(residuals(modelo_final), lag = 12, type = "Ljung-Box", fitdf = 2)
cat("Ljung-Box: Q* =", round(lb_test$statistic, 4),
    "| p-valor =", round(lb_test$p.value, 4), "\n")
```

```
Ljung-Box: Q* = 6.2283 | p-valor = 0.7957
```

Como o p-valor está bem acima de 0,05, não há evidências de autocorrelação serial nos resíduos, confirmando que o modelo capturou toda a estrutura de dependência temporal da série.

Teste de Shapiro-Wilk: o teste de normalidade dos resíduos resultou em $W = 0{,}7882$ com p-valor essencialmente nulo.

```r
sw_test = shapiro.test(residuals(modelo_final))
cat("Shapiro-Wilk: W =", round(sw_test$statistic, 5),
    "| p-valor =", round(sw_test$p.value, 5), "\n")
```

```
Shapiro-Wilk: W = 0.7882 | p-valor = 0
```

A rejeição da normalidade é confirmada também pelo histograma dos resíduos, que exibe cauda pronunciada à direita. Esse resultado indica que os intervalos de predição devem ser interpretados com cautela, pois foram calculados sob premissa gaussiana. Contudo, a ausência de autocorrelação serial garante que as estimativas pontuais são válidas e que a estrutura dinâmica da série foi adequadamente capturada. A assimetria nos resíduos provavelmente reflete os episódios de queda abrupta em janeiro, que geram erros de grande magnitude que dificilmente se normalizam completamente mesmo após a transformação Box-Cox.

8 Comparação de Modelos e Validação Preditiva

8.1 Divisão Treino e Teste

Para avaliar a capacidade preditiva dos modelos em dados não vistos durante o ajuste, a série foi dividida em dois conjuntos: os primeiros 46 meses (janeiro de 2021 a outubro de 2024) foram utilizados para treinamento, e os últimos 12 meses (novembro de 2024 a outubro de 2025) foram reservados como conjunto de teste. Cada modelo foi retreinado exclusivamente nos dados de treino e suas previsões para o período de teste foram então comparadas aos valores reais.

```r
library(prophet)

h_teste  = 12
n_total  = length(serie)
n_treino = n_total - h_teste

treino_ts = subset(serie, end   = n_treino)
teste_ts  = subset(serie, start = n_treino + 1)

# --- SARIMA ---
modelo_sarima_treino = Arima(treino_ts,
                             order    = c(0, 1, 1),
                             seasonal = c(0, 1, 1),
                             lambda   = lambda_valor)
prev_sarima = forecast(modelo_sarima_treino, h = h_teste)

# --- ETS ---
modelo_ets_treino = ets(treino_ts)
prev_ets = forecast(modelo_ets_treino, h = h_teste)

# --- Prophet ---
df_prophet_treino = data.frame(
  ds = dados$data_ref[1:n_treino],
  y  = dados$Custo_Real[1:n_treino]
)
df_prophet_teste = data.frame(
  ds = dados$data_ref[(n_treino + 1):n_total]
)

modelo_prophet_treino = prophet(
  yearly.seasonality = TRUE,
```

```
  weekly.seasonality = FALSE,
  daily.seasonality  = FALSE
)
modelo_prophet_treino = add_country_holidays(modelo_prophet_treino,
                                             country_name = "BR")
modelo_prophet_treino = fit.prophet(modelo_prophet_treino, df_prophet_treino)

prev_prophet_teste = predict(modelo_prophet_treino, df_prophet_teste)
```

8.2 Comparação SARIMA, ETS e Prophet

Três abordagens foram avaliadas sobre o conjunto de teste. O **ETS** (*Error-Trend-Seasonal*) é um modelo de alisamento exponencial com espaço de estados que decompõe a série em componentes de erro, tendência e sazonalidade, selecionando automaticamente entre estruturas aditivas e multiplicativas com base nos critérios de informação. O **Prophet**, desenvolvido pela Meta, é um modelo aditivo baseado em regressão que representa a série como a soma de uma tendência flexível, sazonalidades determinísticas estimadas via séries de Fourier e efeitos de feriados nacionais. Por não pressupor estacionariedade nem requerer diferenciação, o Prophet é robusto a quebras de tendência, mas pode ser menos preciso em séries com autocorrelação residual forte, situação em que modelos da família ARIMA costumam ser mais adequados.

```
rmse_fn = function(real, prev) sqrt(mean((real - prev)^2))
mape_fn = function(real, prev) mean(abs((real - prev) / real)) * 100

y_real    = as.numeric(teste_ts)
y_sarima  = as.numeric(prev_sarima$mean)
y_ets     = as.numeric(prev_ets$mean)
y_prophet = prev_prophet_teste$yhat

tab_comp = data.frame(
  Modelo = c("SARIMA(0,1,1)(0,1,1)[12]",
             "ETS (seleção automática)",
             "Prophet"),
  RMSE   = c(rmse_fn(y_real, y_sarima),
             rmse_fn(y_real, y_ets),
             rmse_fn(y_real, y_prophet)),
  MAPE   = c(mape_fn(y_real, y_sarima),
             mape_fn(y_real, y_ets),
             mape_fn(y_real, y_prophet))
)
```

```r
tab_comp = tab_comp %>%
  mutate(
    RMSE = scales::number(RMSE, big.mark = ".", decimal.mark = ",", accuracy = 1),
    MAPE = paste0(round(MAPE, 2), "%")
  )

kable(tab_comp, align = "lcc", col.names = c("Modelo", "RMSE (R$)", "MAPE"))
```

Tabela 3: Comparação do desempenho preditivo fora da amostra (conjunto de teste: 12 meses, nov/2024 a out/2025).

Modelo	RMSE (R$)	MAPE
SARIMA(0,1,1)(0,1,1)[12]	1.462.587	77.04%
ETS (seleção automática)	1.689.251	87.6%
Prophet	4.137.290	272.05%

```r
datas_teste = dados$data_ref[(n_treino + 1):n_total]

df_comp = data.frame(
  Data    = datas_teste,
  Real    = y_real,
  SARIMA  = y_sarima,
  ETS     = y_ets,
  Prophet = y_prophet
) %>%
  pivot_longer(cols      = c(Real, SARIMA, ETS, Prophet),
               names_to  = "Serie",
               values_to = "Valor")

ggplot(df_comp, aes(x = Data, y = Valor, color = Serie, linetype = Serie)) +
  geom_line(linewidth = 0.9) +
  scale_color_manual(values = c("Real"    = "black",
                                "SARIMA"  = "steelblue",
                                "ETS"     = "tomato",
                                "Prophet" = "green4")) +
  scale_linetype_manual(values = c("Real"    = "solid",
                                   "SARIMA"  = "dashed",
                                   "ETS"     = "dotdash",
                                   "Prophet" = "dotted")) +
  scale_y_continuous(labels = scales::label_number(prefix = "R$ ",
                                                   big.mark = ".",
```

```
                                                    decimal.mark = ",")) +
  theme_minimal() +
  labs(x = "Mês", y = "Custo Real (R$)", color = NULL, linetype = NULL)
```

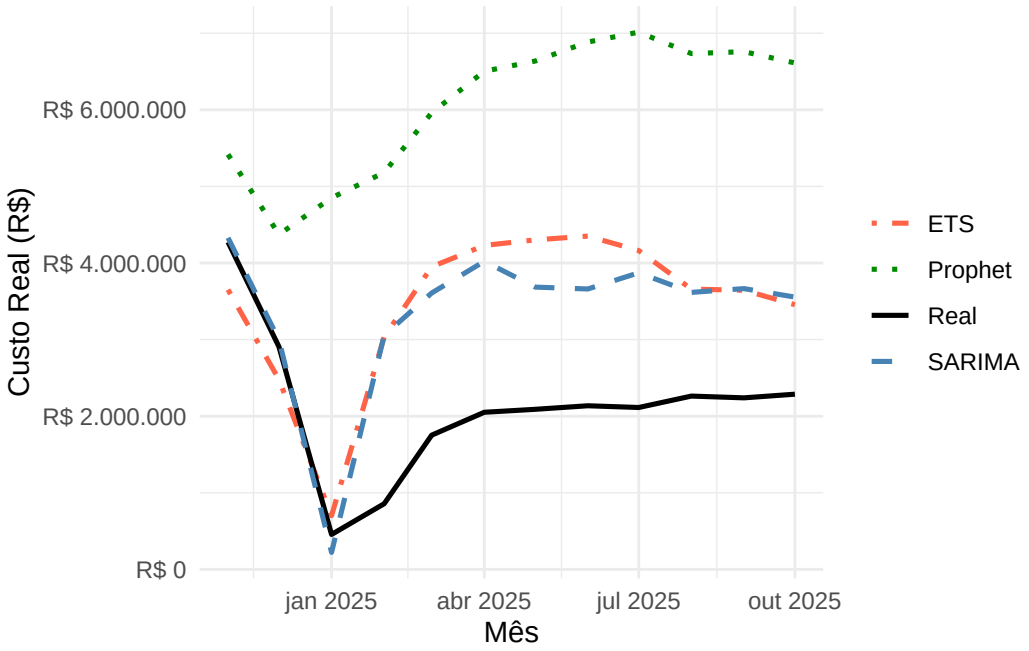

Figura 8: Comparação das previsões do SARIMA, ETS e Prophet sobre o conjunto de teste (nov/2024 a out/2025), com os valores reais em preto.

Os resultados da comparação são expressivos. O SARIMA$(0,1,1)(0,1,1)_{12}$ obteve RMSE de R$1.462.587 e MAPE de 77,04%, desempenho claramente superior ao ETS, que registrou RMSE de R$1.689.251 e MAPE de 87,6%. O Prophet apresentou o pior resultado entre os três, com RMSE de R$4.137.290 e MAPE de 272,05%, evidenciando que sua estrutura de previsão foi inadequada para esta série.

A Figura 8 explica visualmente por que o Prophet falhou de forma tão acentuada: enquanto a série real se manteve em patamares entre R$2 e R$3 milhões ao longo do período de teste, o Prophet projetou uma trajetória fortemente ascendente, chegando a prever valores próximos de R$6 milhões no segundo semestre. Esse comportamento ocorre porque o Prophet, ao ajustar uma tendência flexível, extrapolou o crescimento observado entre 2021 e 2023 sem reconhecer que a série havia estabilizado a partir de 2024. Sem o conceito de diferenciação, ele não consegue distinguir uma tendência encerrada de uma tendência em curso, tornando-o vulnerável a séries com mudanças estruturais como a analisada aqui. O ETS ficou mais próximo dos valores reais, mas ainda superestimou os custos de forma consistente, provavelmente porque sua componente de tendência também projetou crescimento onde havia estabilização.

O SARIMA foi o único modelo capaz de capturar tanto a ausência de tendência crescente no período recente quanto o padrão sazonal de queda em janeiro, resultado que decorre diretamente do processo de diferenciação aplicado, o qual remove a dependência de nível e deixa o modelo responder apenas à estrutura de autocorrelação residual.

9 Resultados

9.1 Estimativas dos Parâmetros

Os coeficientes estimados do modelo SARIMA$(0,1,1)(0,1,1)_{12}$ ajustado sobre toda a série histórica são apresentados na Tabela 4.

```
coef_df = data.frame(
  Coeficiente   = c("ma1  ($\\hat{\\theta}_1$)", "sma1 ($\\hat{\\Theta}_1$)"),
  Estimativa    = c(-0.5885,  0.6412),
  `Erro Padrão` = c( 0.1142,  0.3495),
  check.names   = FALSE
)

kable(coef_df, align = "lcc", row.names = FALSE, escape = FALSE)
```

Tabela 4: Coeficientes estimados do modelo SARIMA(0,1,1)(0,1,1)[12] com transformação Box-Cox (lambda = 0,2997).

Coeficiente	Estimativa	Erro Padrão
ma1 ($\hat{\theta}_1$)	-0.5885	0.1142
sma1 ($\hat{\Theta}_1$)	0.6412	0.3495

O coeficiente $\hat{\theta}_1 = -0{,}5885$ é precisamente estimado, com erro padrão de 0,1142 — razão sinal-ruído que indica significância estatística clara. O coeficiente sazonal $\hat{\Theta}_1 = 0{,}6412$ apresenta erro padrão de 0,3495, maior em termos relativos, o que reflete a maior incerteza inerente à estimação do componente sazonal com apenas cinco ciclos anuais completos na amostra.

9.2 Previsão para os Próximos 12 Meses

Com o modelo validado e ajustado sobre toda a série histórica, realizou-se a projeção dos custos para os 12 meses subsequentes ao último período observado (outubro de 2025). A Figura 9 apresenta graficamente as previsões com os intervalos de predição de 80% e 95%.

```
previsao = forecast(modelo_final, h = 12)

autoplot(previsao) +
  ggtitle("Previsão do Custo Real - Próximos 12 Meses") +
  xlab("Ano") + ylab("Custo Real (R$)") +
```

```
  theme_minimal() +
  scale_y_continuous(
    labels = scales::label_number(prefix = "R$ ",
                                  big.mark = ".",
                                  decimal.mark = ",")
  )
```

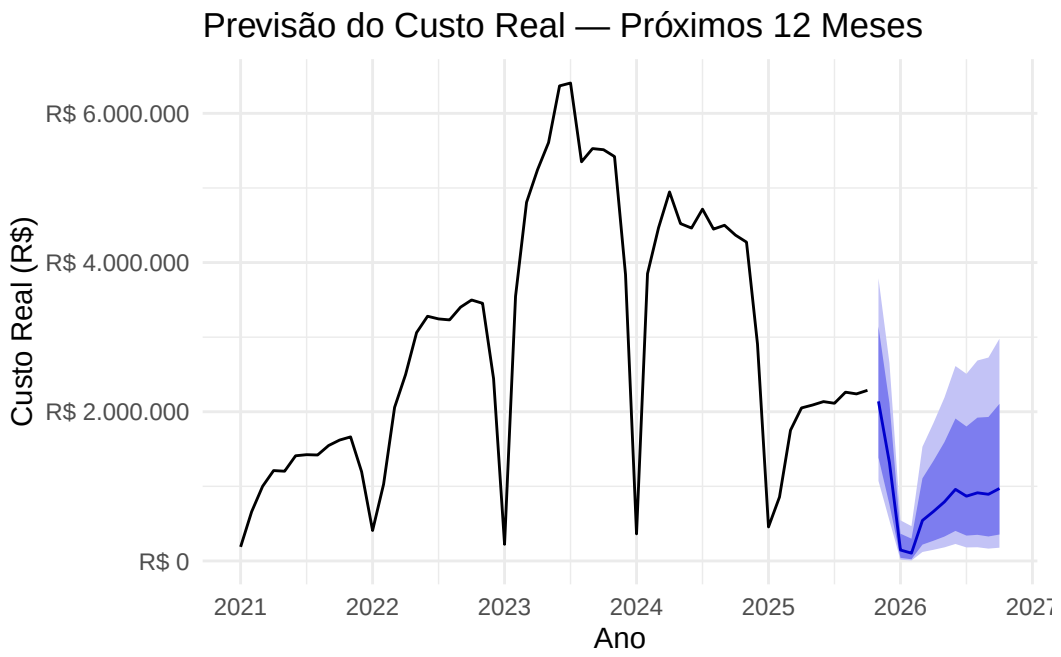

Figura 9: Previsão do custo real com servidores contratados para os próximos 12 meses, com intervalos de predição de 80% e 95%.

A Tabela 5 apresenta os valores pontuais previstos e os limites dos intervalos de predição de 80% e 95% para cada mês do horizonte de previsão.

```
datas_prev = seq(
  from       = max(dados$data_ref) %m+% months(1),
  by         = "month",
  length.out = 12
)

tab_prev = data.frame(
  `Período`  = format(datas_prev, "%b/%Y"),
  `Previsão` = scales::number(as.numeric(previsao$mean),
```

```r
                                prefix = "R$ ", big.mark = ".",
                                decimal.mark = ",", accuracy = 1),
  `LI 80%`   = scales::number(as.numeric(previsao$lower[, 1]),
                                prefix = "R$ ", big.mark = ".",
                                decimal.mark = ",", accuracy = 1),
  `LS 80%`   = scales::number(as.numeric(previsao$upper[, 1]),
                                prefix = "R$ ", big.mark = ".",
                                decimal.mark = ",", accuracy = 1),
  `LI 95%`   = scales::number(as.numeric(previsao$lower[, 2]),
                                prefix = "R$ ", big.mark = ".",
                                decimal.mark = ",", accuracy = 1),
  `LS 95%`   = scales::number(as.numeric(previsao$upper[, 2]),
                                prefix = "R$ ", big.mark = ".",
                                decimal.mark = ",", accuracy = 1),
  check.names = FALSE
)

kable(tab_prev, align = "lrrrrr")
```

Tabela 5: Previsões mensais do custo real com servidores contratados (R$), com intervalos de predição de 80% e 95%.

Período	Previsão	LI 80%	LS 80%	LI 95%	LS 95%
nov/2025	R$ 2.139.176	R$ 1.385.081	R$ 3.142.240	R$ 1.073.030	R$ 3.788.092
dez/2025	R$ 1.315.372	R$ 756.432	R$ 2.113.970	R$ 541.210	R$ 2.650.745
jan/2026	R$ 146.471	R$ 41.414	R$ 365.401	R$ 16.314	R$ 544.315
fev/2026	R$ 104.432	R$ 22.346	R$ 298.598	R$ 6.450	R$ 466.394
mar/2026	R$ 543.059	R$ 219.225	R$ 1.107.347	R$ 119.931	R$ 1.530.209
abr/2026	R$ 663.110	R$ 271.040	R$ 1.341.789	R$ 149.818	R$ 1.848.646
mai/2026	R$ 792.218	R$ 327.022	R$ 1.593.254	R$ 182.237	R$ 2.189.869
jun/2026	R$ 959.449	R$ 402.962	R$ 1.908.840	R$ 227.757	R$ 2.612.564
jul/2026	R$ 867.724	R$ 339.919	R$ 1.802.151	R$ 181.330	R$ 2.508.077
ago/2026	R$ 913.211	R$ 350.263	R$ 1.920.949	R$ 183.519	R$ 2.686.529
set/2026	R$ 893.758	R$ 327.980	R$ 1.930.059	R$ 165.384	R$ 2.726.418
out/2026	R$ 971.141	R$ 354.087	R$ 2.105.118	R$ 177.540	R$ 2.977.973

As previsões reforçam o padrão sazonal historicamente observado. A queda pronunciada projetada para janeiro de 2026, com previsão de R$146.471, reproduz o comportamento recorrente de encerramento de contratos ao final do exercício, que aparece com regularidade em cada janeiro da série histórica. A partir de fevereiro, o modelo projeta retomada gradual dos gastos ao longo do primeiro semestre, convergindo para patamares entre R$800 mil e R$1

milhão no segundo semestre de 2026, bem abaixo dos picos de 2023, consistentemente com a estabilização observada desde 2024.

Os intervalos de predição se alargam progressivamente ao longo do horizonte de previsão, refletindo a incerteza crescente sobre observações futuras individuais — característica inerente a qualquer modelo de previsão. Vale notar que, diferentemente da análise de regressão clássica, em séries temporais as bandas reportadas pelo `forecast()` já correspondem a intervalos de predição, que incorporam tanto a variância do erro futuro quanto a incerteza dos parâmetros estimados. A assimetria dos intervalos, mais largos para cima do que para baixo em vários meses, é consequência da transformação Box-Cox, que preserva a restrição de que custos não podem ser negativos e resulta em distribuições preditivas assimétricas na escala original.

Referências

BOX, G. E. P.; JENKINS, G. M.; REINSEL, G. C. *Time Series Analysis: Forecasting and Control*. 5. ed. Hoboken: John Wiley & Sons, 2015.

CRYER, J. D.; CHAN, K.-S. *Time Series Analysis: With Applications in R*. 2. ed. Nova York: Springer, 2008.

HYNDMAN, R. J.; ATHANASOPOULOS, G. *Forecasting: Principles and Practice*. 3. ed. Melbourne: OTexts, 2021. Disponível em: https://otexts.com/fpp3/.

PREFEITURA MUNICIPAL DE UBERLÂNDIA. *Portal da Transparência: Catálogo de Dados Abertos*. Uberlândia, MG. Disponível em: https://www.uberlandia.mg.gov.br/portal-da-transparencia/dados-abertos/catalogo-de-dados-abertos/. Acesso em: 21 mar. 2026.

TAYLOR, S. J.; LETHAM, B. Forecasting at Scale. *The American Statistician*, v. 72, n. 1, p. 37–45, 2018. Disponível em: https://doi.org/10.1080/00031305.2017.1380080.